

目 录

第 1 章 AI 系统概述	/ 1	1.3 AI 系统架构介绍	/ 19
1.1 AI 历史与现状	/ 1	1.4 AI 系统与 AI 算法关系	/ 27
1.2 AI 发展驱动力	/ 11		

第一篇 AI 硬件与体系结构

第 2 章 AI 计算体系	/ 37	4.6 NVLink 原理剖析	/ 186
2.1 引言	/ 37	4.7 NVSwitch 深度解析	/ 194
2.2 AI 计算模式	/ 41	第 5 章 TPU——以谷歌为例	/ 202
2.3 关键设计指标	/ 57	5.1 引言	/ 202
2.4 核心计算之矩阵乘	/ 63	5.2 谷歌 TPU v1 脉动阵列	/ 212
2.5 计算之比特位宽	/ 67	5.3 谷歌 TPU v2 训练芯片	/ 219
第 3 章 AI 芯片体系	/ 72	5.4 谷歌 TPU v3 Pod 服务器	/ 228
3.1 CPU 基础	/ 72	5.5 谷歌 TPU v4 与光路交换	/ 235
3.2 CPU 指令集架构	/ 81	第 6 章 NPU——以昇腾为例	/ 244
3.3 CPU 计算本质	/ 94	6.1 引言	/ 244
3.4 CPU 计算时延	/ 99	6.2 昇腾 AI 处理器	/ 251
3.5 GPU 基础	/ 104	6.3 昇腾 AI 核心单元	/ 259
3.6 AI 专用芯片基础	/ 123	6.4 昇腾数据布局转换	/ 273
第 4 章 GPU——以英伟达为例	/ 130	第 7 章 AI 芯片思考与展望	/ 279
4.1 引言	/ 130	7.1 GPU 架构与 CUDA 关系	/ 279
4.2 Tensor Core 基本原理	/ 154	7.2 从 GPU 对 AI 芯片思考	/ 285
4.3 Tensor Core 架构演进	/ 160	7.3 AI 芯片发展方向	/ 291
4.4 Tensor Core 深度剖析	/ 171	7.4 超异构计算	/ 298
4.5 分布式通信	/ 179		

第二篇 AI 编译与计算架构

第 8 章 传统编译器	/ 311	8.2 传统编译器介绍	/ 318
8.1 引言	/ 311	8.3 GCC 基本介绍与特征	/ 324

8.4	LLVM 架构设计和原理	/ 329	10.9	代数简化	/ 420
8.5	LLVM IR 基本概念	/ 334	第 11 章	后端优化	/ 425
8.6	LLVM IR 细节详解	/ 340	11.1	引言	/ 425
8.7	LLVM 前端和优化层	/ 345	11.2	计算与调度	/ 428
8.8	LLVM 后端代码生成	/ 350	11.3	算子手工优化	/ 434
第 9 章	AI 编译器	/ 356	11.4	算子循环优化	/ 440
9.1	引言	/ 356	11.5	指令和存储优化	/ 447
9.2	AI 编译器历史阶段	/ 365	11.6	Auto-Tuning 原理	/ 452
9.3	AI 编译器基本架构	/ 371	第 12 章	计算架构	/ 454
9.4	AI 编译器挑战与思考	/ 378	12.1	芯片的编程体系	/ 454
第 10 章	前端优化	/ 388	12.2	SIMD & SIMT 与芯片架构	/ 456
10.1	引言	/ 388	12.3	SIMD & SIMT 与编程关系	/ 465
10.2	图算 IR	/ 389	12.4	CUDA 计算结构	/ 470
10.3	算子融合	/ 393	第 13 章	CANN&Ascend C 计算架构	/ 475
10.4	布局转换原理	/ 400	13.1	昇腾异构计算架构 CANN	/ 475
10.5	内存分配算法	/ 406	13.2	CANN 与算子	/ 482
10.6	常量折叠原理	/ 412	13.3	算子开发编程语言 Ascend C	/ 485
10.7	公共子表达式消除原理	/ 415	13.4	Ascend C 语法扩展	/ 492
10.8	死代码消除	/ 417	13.5	Ascend C 编程范式——以向量为例	/ 500

第三篇 AI 推理系统与引擎

第 14 章	推理系统	/ 511	16.1	引言	/ 585
14.1	引言	/ 511	16.2	量化基本原理	/ 586
14.2	推理系统介绍	/ 515	16.3	感知量化训练	/ 592
14.3	推理流程全景	/ 523	16.4	训练后量化与部署	/ 598
14.4	推理系统架构	/ 526	16.5	模型剪枝原理	/ 604
14.5	推理引擎架构	/ 530	16.6	知识蒸馏原理	/ 611
14.6	昇腾推理引擎 MindIE	/ 549	第 17 章	模型转换	/ 619
14.7	昇腾计算语言 AscendCL	/ 552	17.1	引言	/ 619
第 15 章	模型小型化	/ 561	17.2	推理文件格式	/ 626
15.1	推理参数了解	/ 561	17.3	自定义计算图	/ 634
15.2	CNN 模型小型化	/ 563	17.4	模型转换流程	/ 643
15.3	Transformer 模型小型化	/ 579	第 18 章	计算图优化架构	/ 647
第 16 章	模型轻量化	/ 585	18.1	引言	/ 647

18.2	离线图优化技术	/ 651	19.3	Im2Col 算法	/ 690
18.3	其他计算图优化	/ 667	19.4	Winograd 算法	/ 698
第 19 章	Kernel 优化	/ 676	19.5	QNNPACK 算法	/ 705
19.1	引言	/ 676	19.6	推理内存布局	/ 715
19.2	卷积计算原理	/ 680			

第四篇 AI 框架核心模块

第 20 章	AI 框架基础	/ 721	22.1	引言	/ 790
20.1	引言	/ 721	22.2	计算图基本原理	/ 791
20.2	AI 框架作用	/ 721	22.3	计算图与自动微分	/ 798
20.3	AI 框架之争	/ 727	22.4	计算图的调度与执行	/ 804
20.4	AI 框架的编程范式	/ 735	22.5	计算图的控制流实现	/ 811
20.5	昇思 MindSpore 关键特性	/ 741	22.6	动态图与静态图转换	/ 818
第 21 章	自动微分	/ 753	第 23 章	分布式并行	/ 823
21.1	引言	/ 753	23.1	引言	/ 823
21.2	什么是微分	/ 753	23.2	数据并行	/ 823
21.3	微分计算模式	/ 760	23.3	数据并行进阶	/ 837
21.4	微分实现方式	/ 768	23.4	张量并行	/ 849
21.5	动手实现自动微分	/ 775	23.5	流水并行	/ 855
21.6	动手实现 PyTorch 微分	/ 778	23.6	混合同行	/ 858
21.7	自动微分的挑战和未来	/ 784	23.7	昇思 MindSpore 并行	/ 860
第 22 章	计算图	/ 790			

参考文献	/ 867
索引	/ 883
彩图	